

兵工学报
Acta Armamentarii
ISSN 1000-1093, CN 11-2176/TJ

《兵工学报》网络首发论文

题目: 基于注意力机制增强残差网络的雷达信号调制类型识别
作者: 吕鹏程, 吴礼洋, 刘超, 李文强
收稿日期: 2022-04-25
网络首发日期: 2022-09-20
引用格式: 吕鹏程, 吴礼洋, 刘超, 李文强. 基于注意力机制增强残差网络的雷达信号调制类型识别[J/OL]. 兵工学报.
<https://kns.cnki.net/kcms/detail/11.2176.TJ.20220919.1407.004.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于注意力机制增强残差网络的雷达信号 调制类型识别

吕鹏程¹, 吴礼洋², 刘超³, 李文强²

(1.95183 部队, 湖南 邵东 422000; 2.空军通信士官学校 辽宁 大连 116600; 3.95291 部队, 湖南 衡阳 421000)

摘要：针对情报分析中在低信噪比下雷达信号调制样式识别率较低的问题，提出了基于注意力机制增强残差网络的雷达调制类型识别方法。该方法首先利用平滑伪 Wigner-Ville 分布时频变换的强能量聚集特点将信号调制样式转化为二维时频图像，然后搭建 2 层卷积网络和 6 层残差块的残差网络，并在网络之间穿插加入卷积注意力机制模块，用以增强对特征的关注度，提高特征提取的有效性，最后将二维时频图像输入到该网络模型中实现调制类型识别。仿真实验表明，该方法对 6 类典型雷达信号调制类型能够有效提取到时频图像的特征，在信噪比 0dB 以上实现 100% 的正确率，在信噪比 -10dB 下正确率依然能够保持 94.2%，具有较强的识别优势。

关键词：信号调制类型识别；平滑伪 Wigner-Ville 分布；卷积神经网络；残差网络；注意力机制

中图分类号：TN97.1

文献标志码：A

文章编号：1000-1093(2022)xx-xxxx-xx

DOI:10.12382/bgxb.2022.0302

Radar Signal Modulation Type Recognition Based on Residual Networks Enhanced by Attention Mechanism

GUO Pengcheng¹ WU Liyang² LIU Chao³ LI Wenqiang²

(1.Unit 95183 of PLA, Hunan Shaodong 422800, China; 2.Air Force Communication NCO Academy, Liaoning Dalian 116600, China; 3.Unit 95291 of PLA, Hunan Hengyang 421000, China)

Abstract: Aiming at the problem of radar signal modulation type low recognition rate under the condition of low SNR in intelligence analysis, an radar signal modulation type recognition method based on residual networks enhanced by attention mechanism is proposed. Firstly, due to the strong energy aggregation characteristics of the smooth pseudo Wigner Ville distribution time-frequency transform, the signal modulation type is transformed into a two-dimensional time-frequency image. Then, a two-layer convolution networks and a six-layer residual block residual networks are built, and the convolutional block attention module is inserted between the networks to enhance the attention to features and improve the effectiveness of feature extraction. Finally, two-dimensional time-frequency images are input into the network model to realize modulation type recognition. Simulation result shows that this method can effectively extract the feature of time-frequency images for six sorts of typical radar signal modulation type. The method can achieve 100% above 0dB Signal-Noise Ratio, and still maintain 94.2% under -10dB Signal-Noise Ratio.

Keywords: signal modulation type recognition; smooth pseudo Wigner Ville distribution;

收稿日期：2022-04-25

基金项目：国家自然科学基金项目 (61804184)

作者简介：吕鹏程(1993—), 男, 工程师, 硕士。E-mail: gpcfly@163.com

0 引言

雷达辐射源识别作为电子情报分析(ELINT)的重要一环,也是开展分析雷达平台类型、工作状态、工作模式以及威胁程度等信息的基础^[1-2]。雷达识别主要依靠提取到的脉间参数,如脉冲频率、脉冲宽度、到达方向、脉冲重复间隔等,与数据库进行比对从而得到相关雷达信息。而随着雷达技术的发展,信号复杂程度以及电磁环境复杂程度日益增加,尤其出现的低截获概率(LPI)^[3-4]雷达信号更是使得脉间参数难以满足识别准确率的要求。因此脉内调制信息也逐渐成为一项重要的匹配参数用于雷达辐射源识别,而国内外学者对调制样式识别方法开展的探索也是一项研究热点。

对调制样式的特征提取,已有了大量人工特征选择的方法^[5-6],但是这些特征在低信噪比下识别率往往捉襟见肘。近年来,人们利用深度学习方法的比重越来越重,主要是因为使用神经网络自学习的强大功能,往往能够获得深层、抽象的特征,相比于人工选择的浅层特征,一方面可以减少特征选择工作量,另一方面提取到的特征能够更有效提高识别率^[7-8],在一定程度上可减少低信噪比带来的影响。卷积神经网络对图像有着独特的特征提取优势,许多文献都是将信号进行相关时频变换得到二维时频图像,进而转化为卷积网络对图像的识别问题。文献[9]利用 LeNet-5 卷积网络学习信号时频特征,并将特征输入到字典学习的分类器中进行识别,在 0dB、小样本条件下实现了 98% 的识别率;文献[10]首先使用模糊函数主脊坐标变换进行信号调制样式特征的一次提取,随后输入到卷积网络中进行分类识别,在 -6dB 条件下实现 94.71% 识别率;文献[11]进行 DS-STFT 时频变换进行浅层特征提取,再将该特征输入到卷积网络中实现了在 -10dB 条件下 90.81% 的识别率。然而上述文献使用的卷积网络层数都比较浅,未能进一步实现深度特征提取,导致识别率的提高受到一定限制。

随着卷积神经网络的发展,研究人员发现随着网络层数进一步增加到一定层数,模

型的分类效果不会更好,反而会变差。He 等^[12]在研究中称该问题为网络退化,因此提出深度残差网络(ResNets),有效解决该问题并将网络深度增至一百多层,极大提高了图像识别的能力水平,是目前深度学习中最为有效的模型之一。雷达辐射源识别领域也是借鉴该模型为解决低信噪比条件下识别率的问题提出了许多识别方法。文献[13]将时域雷达信号输入到 ResNet32 框架中进行训练,实验表明在低信噪比下具有出色的识别率;文献[14]将雷达信号进行 Choi-Williams 分布时频变换,并构建扩张残差网络用以自动提取时频图像特征实现分类识别,在 -6dB 信噪比下,对 16 类雷达辐射源信号整体识别率达到 98.2%;同时注意力机制是图像识别领域的重要方法,在雷达信号识别也得到应用,其具有模仿人类专注于自己感兴趣的事物而忽视无关事物的特性,在低信噪比下更为有效地关注到信号特征,从而提高识别准确率。文献[15]提出注意力机制特征融合一维卷积长短时深度神经网络,在信噪比 -12dB 以上准确率保持 100%。

受此启发,本文提出了一种基于注意力机制增强的残差网络雷达信号调制识别方法。首先对雷达信号采用平滑伪 Wigner-Ville 分布(SPWVD)^[16]得到信号的二维时频图像,利用该时频变化能量聚集度强的优势来反映调制方式的变化情况,具有一定抗干扰性;随后搭建识别模型残差网络,为强化调制样式在时频图像中的表达,利用注意力机制模型(CBAM),提高网络对调制样式相关特征的权重,剔除噪声等冗余,提升网络对噪声的抗干扰性以及特征提取的有效性,同时该模型能够通过恒等映射缓解深层网络梯度弥散和梯度爆炸的问题,提高训练的收敛速度,因此增强残差网络整体性能。实验表明在没有进行去噪的预处理前提下,利用 SPWVD 时频变换和 CBAM 注意力机制自身的抗噪声能力,本文识别方法能够在低信噪比下较高的识别率。

1 SPWVD 时频变换

假设截获到的雷达信号为 $x(t)=s(t)+n(t)$, $s(t)$ 为原始雷达信号, $n(t)$ 为高

斯白噪声, 且 $s(t)$ 与 $n(t)$ 相互独立。信号 $x(t)$ 的 Wigner 分布定义为

$$W_x(t, f) = \int_{-\infty}^{+\infty} x(t - \tau/2) x^*(t + \tau/2) e^{-j\tau 2\pi f} d\tau \quad (1)$$

式中: τ 为积分变量; t 为时移。对 $x(t+\tau/2)$ 和 $x^*(t-\tau/2)$ 乘积部分作傅里叶变换, 即是 t 时刻的 WVD。根据 Hilbert 变换将信号 $x(t)$ 构造解析形式 $z(t)$ 后, Wigner 分布变为 Wigner-Ville 分布:

$$W_z(t, f) = \int_{-\infty}^{+\infty} z(t - \tau/2) z^*(t + \tau/2) e^{-j\tau 2\pi f} d\tau \quad (2)$$

式中:

$$z(t) = x(t) + jH[x(t)] \quad (3)$$


$$H[x(t)] = \lim_{\delta \rightarrow 0} \left[\int_{-\infty}^{-\delta} \frac{x(t-u)}{u} du + \int_{\delta}^{+\infty} \frac{x(t-u)}{u} du \right] \quad (4)$$

由于 Wigner-Ville 分布的时宽带宽积达到不确定性原理给出的下界, 因此相比于其他联合时频分布, Wigner-Ville 分布拥有较好的时频分辨率。


SPWVD 时频分布是由 WVD 分布中加入两个实的偶函数 $g(u)$ 和 $h(\tau)$ 得来的, 其中 $g(u)$ 为时域平滑窗和 $h(\tau)$ 为频域平滑窗,

$$SPWVD(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} z(t-u-\tau/2) z^*(t-u+\tau/2) \cdot g(u) h(\tau) e^{-j2\pi f \tau} du d\tau \quad (5)$$

相对于 WVD, 其可以更好地削弱相干项的影响, 能量和时频聚集性更强, 更容易看出信号的时频关系。图 1 展示了在信噪比为 0dB 下, 非线性调频信号的 SPWVD 和 WVD 时频分布图, 可以看出, 信号 WVD 时频分布在噪声干扰下表达不明显, 且能量聚集程度低; 而 SPWVD 在较低信噪比条件下依然能够显著地展示信号的时频变化, 并且能量更为聚集凸显, 具有一定的抗干扰性。



(a) SPWVD



(b) WVD

图 1 SPWVD 和 WVD 时频分布图对比

Fig.1 Comparison with SPWVD and WVD

2 CBAM 注意力机制

注意力机制经常利用心理学的内容进行解释, 即人类在复杂环境下能够有效关注自己感兴趣、值得注意的点, 而该特性也是注意力机制能够模仿的。CBAM 注意力机制由通道注意力模块 (CAM) 和空间注意力模块 (SAM) 串联而成, 如图 2 所示。其中以证明通道注意力模块在空间注意力模块前效果更好。




图 2 CBAM 注意力机制结构

Fig.2 Construction of CBAM

在通道注意力模块中, 假设输入的特征图 (Feature map) 大小为 $(H \times W \times C)$, 分别代表高度、宽度、通道, 经过全局平均池化 (AvgPool) 和全局最大池化 (MaxPool), 使得高度和宽度压缩为 1, 得到两个 $1 \times 1 \times C$ 的特征图, 再同时送入多层感知器 (MLP) 网络中, 层数为 3 层, 中间层神经元个数为 C/r (r 为减少率), 在本文中 $r=4$, ReLU 函数作为激活函数。经过 MLP 输出后进行特征相加, 采用 sigmoid 激活函数完成映射, 得到通道模块权重 W_c , 与输入的特征图相乘完成通道注意力模块的计算。




图3 通道注意力模块

Fig.3 The CAM

在空间注意力模块中，输入的特征图经过最大池化和平均池化后在通道上进行拼接，得到 $H \times W \times 2$ 的特征图，而后经过卷积核为 7×7 的卷积运算，采用 sigmoid 激活函数完成映射，得到空间模块权重 W_s ，与输入的特征图相乘完成空间注意力模块的计算。




图4 空间注意力模块

Fig.4 The SAM

3 残差网络

残差网络核心在于引入了残差块结构，如图 5 所示。该结构左边使用了“shortcut connection”的连接方式，可以称为跳跃连接或短路连接，右边使用两层卷积神经网络。将输入 x 经过 3×3 卷积核的卷积运算以及批归一化、ReLU 激活映射得到 $F(x)$ ，同时与 x 进行跳跃连接得到 $H(x)=F(x)+x$ ，此时 $F(x)=H(x)-x$ 即为网络残差。若输入 x 与输出 $F(x)$ 的特征维度相同，则直接加和。若维度不同，则与输出 $F(x)$ 维度一致。




图5 残差块结构

Fig.5 Construction of residual

4 基于注意力增强的残差网络识别框架

本文提出注意力增强的残差网络识别

方法，将多个 CBAM 穿插在多个残差块之间，增强残差网络对特征的关注度，提高特征提取能力，整体网络连接如图 6 所示，由 2 个卷积层(Conv2d)、6 个残差块(Residual)、4 个 CBAM 模块、1 个全局平均池化层(GlobalAvgPool2d)、1 个全连接层(Linear)组成。其中 2 个卷积层和 1 个 CBAM 模块组成第一个基础网络块(Baisc Net Block)，后续连续 3 个 Baisc Net Block 都是由 2 个残差块和 1 个 CBAM 模块组成，全局平均池化层对每个特征图求和取平均，将输入维度压缩为 1×1 ，能够生成与类别相对应的特征图，增强特征图与类别的一致性，最后利用全连接层，使用 softmax 分类器进行分类。

本文网络损失函数使用负对数似然(NLL)损失函数；优化方法使用 Adam(Adaptive Moment Estimation)梯度下降方法，其本质上是带有动量项的 RMSprop(Root Mean Square Prop)算法，它利用梯度的一阶矩估计和二阶矩估计动态调整每个参数的学习率。Adam 的优点主要在于经过偏置校正后，每一次迭代学习率都有个确定范围，使得参数比较平稳。

将时频图像预处理为 56×56 像素大小，经过卷积网络、残差网络和 CBAM 模块，在全局平均池化前得到 $7 \times 7 \times 512$ 的特征图，最后送入 softmax 分类层得到调制类别。表 1 为各网络层特征参数的变化值。

表 1 各网络层特征参数

Table 1 Parameters of net features

名称	输入×通道数	输出×通道数
Conv2d_1/卷积层	$56 \times 56 \times 1$	$56 \times 56 \times 32$
Conv2d_2/卷积层	$56 \times 56 \times 32$	$56 \times 56 \times 64$
CBAM/注意力层	$56 \times 56 \times 64$	$56 \times 56 \times 64$
Residual_1/残差层	$56 \times 56 \times 64$	$56 \times 56 \times 64$
Residual_2/残差层	$56 \times 56 \times 64$	$28 \times 28 \times 128$
CBAM/注意力层	$28 \times 28 \times 128$	$28 \times 28 \times 128$
Residual_1/残差层	$28 \times 28 \times 128$	$28 \times 28 \times 128$
Residual_2/残差层	$28 \times 28 \times 128$	$14 \times 14 \times 256$
CBAM/注意力层	$14 \times 14 \times 256$	$14 \times 14 \times 256$
Residual_1/残差层	$14 \times 14 \times 256$	$14 \times 14 \times 256$
Residual_2/残差层	$14 \times 14 \times 256$	$7 \times 7 \times 512$
CBAM/注意力层	$7 \times 7 \times 512$	$7 \times 7 \times 512$
GlobalAvgPool2d	$7 \times 7 \times 512$	$1 \times 1 \times 512$

Linear	1×1×512	1×1×6
--------	---------	-------

在第 2-4 每个 Baisc Net Block 中第 2 个残差块 Residual_2 目的是实现通道增加一倍,特征图尺寸减小一半,给出残差块的卷积参数,如图 7 所示。可以看到残差块 Residual_2 相比于残差块 Residual_1,在跳跃连接线路上增加了卷积核,为了使特征图尺寸减小一半,本文设置卷积核大小为 2×2,步长为 2,填充为 0,保证了通过跳跃连接线路的输入 x 在维度上与残差一致,满足相加运算。




图 7 残差块特征参数
Fig.7 Parameters of residual feature

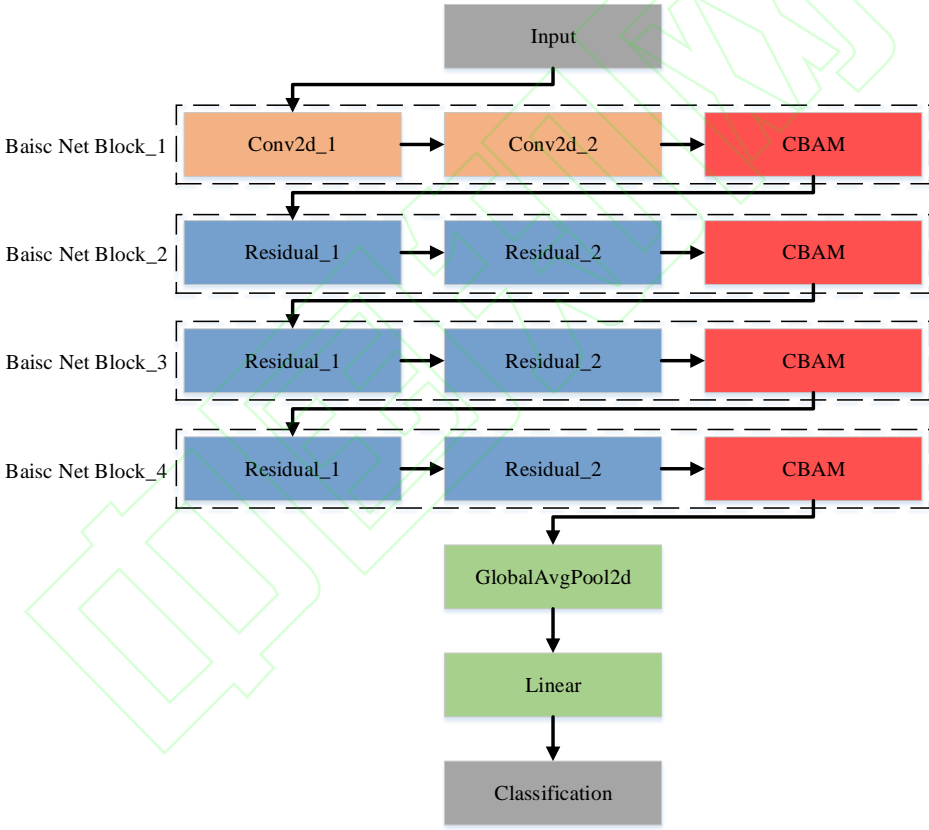


图 6 基于注意力机制增强的残差网络识别框架

Fig.6 Recognition frame of residual networks enhanced by attention mechanism

5 实验及结果分析

5.1 实验信号设置

本文雷达辐射源信号均通过 Low Probability of Intercept Toolbox 产生，产出 6 种信号调制类型，参数设置如表 2 所示：

表 2 信号参数设置

Table 2 Parameters of signal

类型	载频/ MHz	采样频 率/ MHz	(子) 脉宽/ms	巴克码
CW	7-12	60	1-5	/
BPSK	7-12	60	/	7、11、 13
LFM	10	60	8-16	/

FSK	9-12	60	1	/
NLFM	7-12	60	8-16	/
QPSK	7-12	60	1	/

所有信号参数在取值范围内随机选取，信噪比取值为-20dB、-15 dB、-10 dB、-5 dB、0 dB、5 dB，并且每个信噪比下，每种信号随机产生 1500 个训练样本、500 个测试样本。

信号产生及时频图像数据产生使用

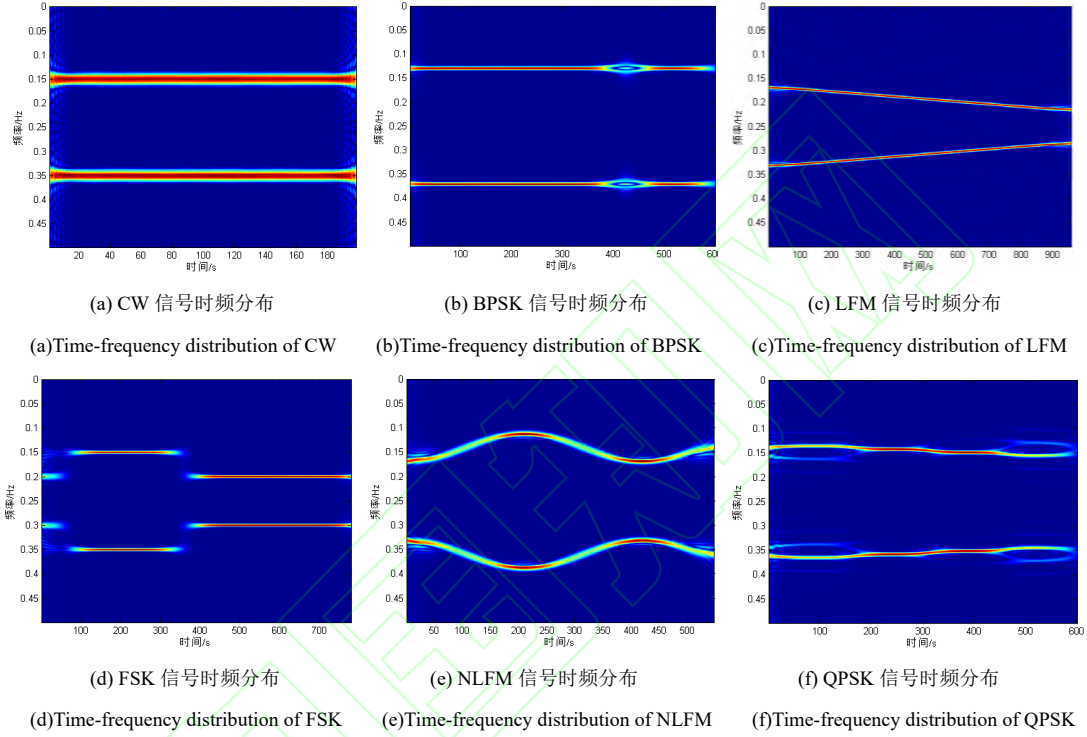


图 8 6 类调制信号的 SPWVD 时频分布图

Fig.8 Time-frequency distribution of 6 modulation signals

5.2 识别网络整体性能分析

图 9 展示了在信噪比为-10dB 下，网络迭代 100 次的训练误差、测试误差和识别率曲线图。可以看出，网络训练中，训练集和测试集很快得到收敛，识别率也是在前 9 次迭代后迅速从 57%上升至 90%，在经过 94 次迭代后，误差及识别率趋于稳定。

MATLAB 平台；网络搭建及训练使用 Pytorch 学习框架；计算机配置：CPU 为 Inter(R) Core(TM) i7-8750H, 8GB 内存, GPU 为 NVIDIA GeForce GTX 1050Ti。

图 8 展示了 6 类调制信号 SPWVD 时频分布图。可以看出除了 NLFM 和 FSK 信号外，其他 4 种信号在变化趋势上有类似的地方，这给网络训练识别增加了一定难度。




图 9 训练误差、测试误差及识别率

Fig.9 Training loss、test loss and recognition rate

为了对比使用 SPWVD 时频变换的优势，使用 WVD 时频变换重新作为输入到本文网络中（称为 WVD+Our），并且将本文方法与 LeNet-5 及 Ori-ResNet 两种卷积网络进行对

比，其中 LeNet-5 为经典的手写识别卷积网络；Ori-ResNet 为本文网络去掉注意力机制后剩下的网络。图 10 为 3 种网络的识别率对比图。可以看出，WVD 时频变换由于能量聚集性较差，使得在低信噪比下网络很难从中提取到有效特征，使得识别率快速下降；同时在信噪比较好的情况下（0dB 及以上），各网络都能进行很好的识别，而当信噪比降到 0dB 以下，网络性能出现很大差距，本文方法在-10dB 保持有 94.2%的准确率，在-20dB 依然有 63.1%的准确率；相比于 Ori-ResNet 网络，说明本文使用的注意力增强的残差网络对噪声有着较好的抗干扰性，对特征提取有有效的促进作用；相比于 LeNet-5 网络，说明网络层数增加能够进一步提高识别率，而残差网络的优势能够确保网络加深的同时保持性能良好。

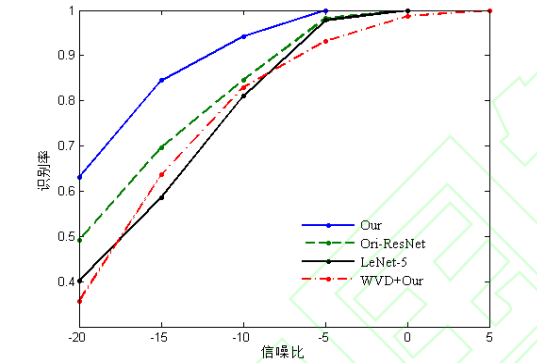


图 10 识别率对比

Fig.10 Comparison of recognition rate

5.3 网络特征可视化及注意力机制分析

为了展示每层网络提取到了什么样的特征，在此进行特征可视化操作，以信噪比 0dB 的一个 NLFM 信号为例，如图 11 所示，分别提取到第 1、2 个卷积层、第 1、2、3、4 个 CBAM 的特征，每层网络取出前 12 个通道作为示例，如图 12 所示。由图 12 可以看出，卷积层的操作是对时频信号图像的纹理方面进行提取；CBAM 操作是增强了对图像中时频信号能量较高的部分的关注度，从图中可以看出，每个通道对图像特征都有所响应，说明每个卷积核都参与了学习，并且随着网络加深，提取到的特征越抽象。






图 11 输入网络的 NLFM 信号示例

Fig.11 Example of NLFM



(a) 第 1 个卷积层可视化特征图

(a) Visual feature diagram of first convolutional layer



(b) 第 2 个卷积层可视化特征图

(b) Visual feature diagram of second convolutional layer

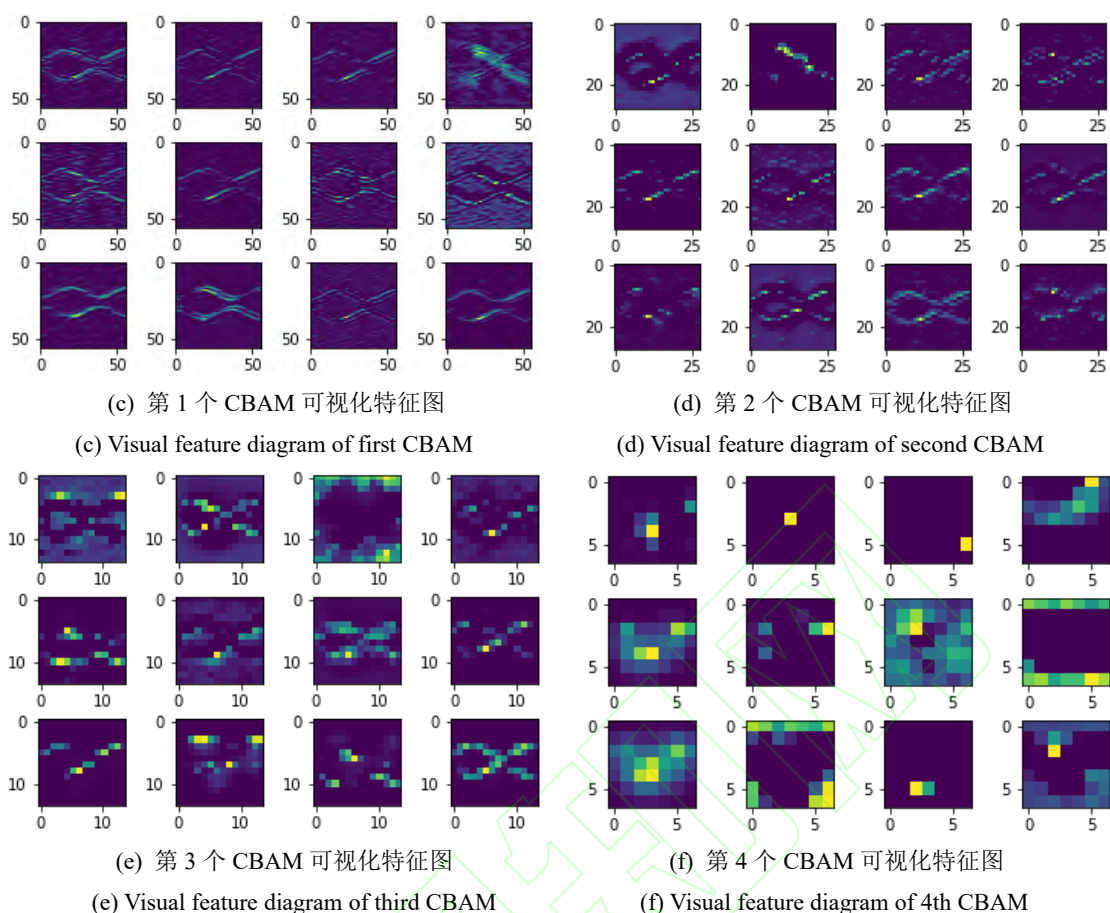


图 12 提取到网络层特征可视化图例

Fig.12 Visual feature diagram of net layer feature

为进一步分析加入注意力机制模块 CBAM 对网络识别率的影响,将去掉所有注意力机制的网络 Ori-ResNet 为基础,沿着本文网络框架从上往下依次增加注意力机制模块,每增加一个 CBAM 进行一次实验,得到的识别率对比如图 13 所示。可以看出每增加一个 CBAM,识别率都有所增加。增加第 3 个 CBAM 时,识别率有一个较大的提升,说明第 3 个注意力机制关注的特征更具区分性。

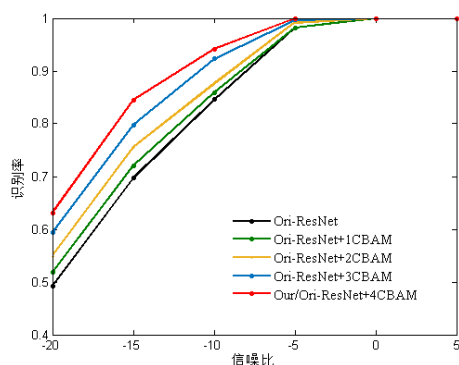


图 13 不同 CBAM 数量的识别率对比

Fig.13 Comparison of different number of CBAM

5.4 不同算法对比

为进一步验证本文方法的优势,与文献[9](LeNet-FisherDDL),文献[17](MRSAF-DBN),文献[18](Chrip-Zernike-ResNet)分别在信噪比-20dB、-10dB、0dB 下进行对比,如表 3 所示。可以看出本文在低信噪比条件下具有较强的优势,尤其在信噪比-10dB 下,相比于其他三种算法,识别率分别高出 26.5%、20.7%、24.1%其中本文方法相比于 LetNet-5 网络更深,提取时频信号特征更为有效;与文献[17]采用的模糊函数主脊切片特征相比,SPWVD 时频图像保留更丰富的特征信息;使用注意力机制模块,提高了残差网络对噪声的抗干扰性,因此效果比文献[18]方法识别效果较好。

表 3 不同算法识别率

Table 3 Recognition of different algorithms

%	
信噪比/dB	

识别方法	-20	-10	0
LeNet-FisherDDL	45.6	67.7	98.0
MRSFAF-DBN	51.4	73.5	98.4
Chrip-Zernike-ResNet	58.6	70.1	99.1
Our	63.1	94.2	100

6 结论

针对情报分析中在低信噪比下雷达信号调制样式识别率的问题,本文提出利用注意力机制强化残差网络特征提取及识别的方法,并进行了仿真验证。得出以下主要结论:

1) 时频变化作为输入网络前的第 1 次特征提取,需要得到清晰、明显的二维时频图像;SPWVD 可很好地反映信号调制样式的时频关系,并且具有较强的抗干扰性。

2) 网络深度越深,特征提取的效果越好,但会出现网络退化问题,残差网络能够有效解决该问题,使得网络层数可进一步加深。

3) 注意力机制可以提高网络对某一特征的关注度,使得提取到的特征更具有区分性;实验表明,CBAM 在信号调制样式识别中,能够有效地关注到噪声干扰下的时频特征,提高了对噪声的抗干扰性,从而提高了识别率。

参考文献 (References)

[1] KISHORE T R, RAO K D. Automatic intrapulse modulation classification of advanced LPI radar waveforms[J]. IEEE Trans. on Aerospace Electronic& Systems, 2017, 53(2): 901-904.

[2] IGLESIAS V, GRAJAL J, ROYER P, et al. Real-time low-complexity automatic modulation classifier for pulsed radar signals[J]. IEEE Transactions on Aerospace Electronic& Systems, 2015, 51(1): 108-126.

[3] LIU Y J, XIAO P, WU H C, et al. LPI radar signal detection based on radial integration of Choi-Williams time-frequency image[J]. Journal of Systems Engineering and Electronics, 2015, 26(5): 973-981.

[4] ZHOU J L, ZHENG S L, YU X B, et al. Low probability of intercept communication based on structured radio beams using machine learning[J].

IEEE Access, 2019, 7: 169946-169952.

[5] 王红卫, 董鹏宇, 陈游, 等. 半监督条件下基于朴素贝叶斯和Choi-Williams时频分布能量积累的雷达信号识别[J]. 电子与信息学报, 2021, 43(3): 589-597.

WANG H W, DONG P Y, CHEN Y, et al. Recognition method of radar signal based on the energy cumulant of Choi-Williams distribution and improved semi-supervised Naïve Bayes[J]. Journal of Electronics & Information Technology, 2021, 43(3): 589-597. (in Chinese)

[6] LIU S K, YAN X P, LI P, et al. Radar emitter recognition based on SIFT position and scale features[J]. IEEE Transactions on Circuits and Systems II: Express Briefs, 65(12), 2062-2066.

[7] 周志文, 黄高明, 高俊. 一种深度学习的雷达辐射源识别算法[J]. 西安电子科技大学学报(自然科学版), 2017, 44(3): 77-82.

ZHOU Z W, HUANG G M, GAO J, et al. Radar emitter identification algorithm based on deep learning[J]. Journal of xidian university, 2017, 44(3): 77-82. (in Chinese)

[8] 郭立民, 寇韵涵, 陈涛, 等. 基于栈式稀疏自编码器的低信噪比下低截获概率雷达信号调制类型识别[J]. 电子与信息学报, 2018, 40(4): 875-881.

GUO L M, KOU Y H, CHEN T, et al. Low probability of intercept radar signal recognition based on stacked sparse auto-encoder[J]. Journal of Electronics & Information Technology, 2018, 40(4): 875-881. (in Chinese)

[9] 吕鹏程, 吴礼洋. 融合卷积特征与判别字典学习的低截获概率雷达信号识别[J]. 兵工学报, 2019, 40(9): 1881-1889.

GUO P C, WU L Y. LPI Radar Signal recognition with convolution feature and discrimination dictionary learning[J]. Acta Armamentarii, 2019, 40(9): 1881-1889.(in Chinese)

[10] 普运伟, 刘涛涛, 郭江, 等. 基于卷积神经网络和模糊函数主脊坐标变换的雷达辐射源信号识别[J]. 兵工学报, 2021, 42(8):1680-1689.

PU Y W, LIU T T, GUO J, et al. Radar emitter signal recognition based on convolutional neural network and coordinate transformation of

- ambiguity function main ridge[J]. *Acta Armamentarii*, 2021, 42(8):1680-1689. (in Chinese)
- [11] 李东瑾, 杨瑞娟, 董睿杰. 基于深度时频特征学习的雷达辐射源识别[J]. *国防科技大学学报*, 2020, 42(6): 112-119.
- LI D J, YANG R J, DONG R J. Radar emitter recognition based on the deep learning of time - frequency feature[J]. *Journal of National University of Defense Technology*, 2020, 42(6): 112-119. (in Chinese)
- [12] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//*Proceedings of IEEE Conference on Computer Vision and Pattern Recognition*. Las Vegas, NV, US:IEEE, 2016: 770-778.
- [13] 徐卓君, 杨雯婷, 杨承志, 等. 雷达脉内调制识别的改进残差神经网络算法[J]. *吉林大学学报(工学版)*, 2021, 51(4): 1454-1460.
- XU Z J, YANG W T, YANG C Z, et al. Improved residual neural network algorithm for radar intra-pulse modulation classification, *Journal of Jilin University (Engineering and Technology Edition)*, 2021, 51(4): 1454-1460. (in Chinese)
- [14] 秦鑫, 黄洁, 查雄, 等. 基于扩张残差网络的雷达辐射源信号识别[J]. *电子学报*, 2020, 48(3): 456-462.
- QIN X, HUANG J, ZHA X, et al. Radar emitter signal recognition based on dilated residual network[J]. *Acta Electronica Sinica*, 2020, 48(3): 456-462. (in Chinese)
- [15] 崔邦彦, 田润澜, 王东风, 等. 基于注意力机制和改进CLDNN的雷达辐射源识别[J]. *系统工程与电子技术*, 2021, 43(5): 1224-1231.
- CUI B Y, TIAN R L, WANG D F, et al. Radar emitter identification based on attention mechanism and improved CLDNN[J]. *Systems Engineering and Electronics*, 2021, 43(5): 1224-1231. (in Chinese)
- [16] FLANDRIN P, BORGNAT P. Time-frequency energy distributions meet compressed sensing[J]. *IEEE Transactions on Signal Processing*, 2010, 58(6): 2974-2982.
- [17] 董鹏宇, 王红卫, 陈游, 等. 基于模糊函数主脊切片和深度置信网络的雷达辐射源信号识别[J]. *空军工程大学学报(自然科学版)*, 2020, 21(2): 84-90.
- DONG P Y, WANG H W, CHEN Y, et al. A recognition method of radar emitter signals based on SVD of MRSAF and DBN[J]. *Journal of Air Force Engineering University (Natural Science Edition)*, 2020, 21(2): 84-90. (in Chinese)
- [18] 谢存祥, 张立民, 钟兆根. 基于时频特征提取和残差神经网络的雷达信号识别[J]. *系统工程与电子技术*, 2021, 43(4): 917-926.
- XIE C X, ZHANG L M, ZHONG Z G. Radar signal recognition based on time-frequency feature extraction and residual neural network[J]. *Systems Engineering and Electronics*, 2021, 43(4): 917-926. (in Chinese)